



Inteligência Artificial Aplicada a Finanças 2.0

Inteligência Artificial Aplicada a Finanças Versão 2.0

Principais Algoritmos Para Previsão de Séries Temporais

Na parte 1 do projeto deste capítulo começamos a estudar Forecasting de séries temporais criando um Modelo Base com Método Naive, que não é necessariamente um modelo, mas sim uma forma de ter uma ideia geral sobre qual seria o comportamento da série no futuro. A partir de agora estudaremos outros modelos.

Para fazer previsões com séries temporais temos diversos algoritmos divididos nestas categorias principais:

Modelos de Regressão de Séries Temporais

O conceito básico é prever a série temporal de interesse y supondo que ela tenha uma relação linear com outras séries temporais x.

Por exemplo, podemos desejar prever vendas mensais y usando o gasto total com publicidade x como um preditor. Ou podemos prever a demanda diária de eletricidade y usando temperatura x1 e o dia da semana x2 como preditores.

A variável y às vezes também é chamada de variável regressante, dependente ou explicada. As variáveis preditoras x às vezes também são chamados de regressores, variáveis independentes ou explicativas.

Exponential Smoothing (Suavização Exponencial)

A "suavização exponencial" foi proposta no final da década de 1950 (Brown, 1959; Holt, 1957; Winters, 1960) e motivou alguns dos métodos de previsão mais bem-sucedidos. As previsões produzidas usando métodos de suavização exponencial são médias ponderadas de observações passadas, com os pesos decaindo exponencialmente à medida que as observações "envelhecem".

Em outras palavras, quanto mais recente a observação, maior o peso associado. Essa estrutura gera previsões confiáveis rapidamente e para uma ampla gama de séries temporais, o que é uma grande vantagem e de grande importância para muitas aplicações comerciais.

Modelos ARIMA (Autoregressive Integrated Moving Average)

Os modelos ARIMA fornecem outra abordagem para a previsão de séries temporais. A suavização exponencial e os modelos ARIMA são as duas abordagens mais usadas para previsão de séries temporais e fornecem abordagens complementares.

Embora os modelos de suavização exponencial sejam baseados em uma descrição da tendência e da sazonalidade nos dados, os modelos ARIMA visam descrever as correlações automáticas nos dados. Modelos ARIMA são técnicas estatísticas avançadas dentro da categoria de Machine Learning.



Modelos de Regressão Dinâmica

Os modelos de Regressão de Séries Temporais, Exponential Smoothing e ARIMA, permitem a inclusão de informações de observações anteriores de uma série, mas não a inclusão de outras informações que também possam ser relevantes. Por exemplo, os efeitos de feriados, atividade da concorrência, mudanças na lei, economia em geral ou outras variáveis externas podem explicar algumas das variações históricas e levar a previsões mais precisas.

Modelos Hierárquicos ou de Séries Agrupadas

As séries temporais geralmente podem ser desagregadas naturalmente por vários atributos de interesse. Por exemplo, o número total de bicicletas vendidas por um fabricante de bicicletas pode ser desagregado por tipo de produto, como bicicletas comuns, mountain bikes, bicicletas infantis e híbridos. Cada um deles pode ser desagregado em categorias mais refinadas. Por exemplo, as bicicletas híbridas podem ser divididas em bicicletas urbanas, de transporte, conforto e trekking, e assim por diante. Essas categorias são aninhadas nas categorias de grupos maiores e, portanto, a coleção de séries temporais segue uma estrutura de agregação hierárquica. Portanto, nos referimos a eles como "séries temporais hierárquicas".

Séries temporais hierárquicas geralmente surgem devido a divisões geográficas. Por exemplo, o total de vendas de bicicletas pode ser desagregado por país, depois dentro de cada país por estado, dentro de cada estado por região e assim por diante.

Métodos Avançados de Previsão de Séries Temporais

Aqui nós temos técnicas de Combinações, Backcasting, Intervalos Para Agregações e Deep Learning (especialmente com modelos LSTM).

Não estudaremos todos esses modelos agora neste projeto, mas abordaremos alguns, dando ênfase aos modelos ARIMA. Mas quase todos os métodos listados acima serão usados nos demais projetos deste curso.

Na parte 2 do projeto vamos aplicar o método Exponential Smoothing.